Основные задачи Computer Vision

Нейронные сети в компьютерном зрении

2026

Введение в Computer Vision

Что такое Computer Vision?

Преобразование визуальных данных в высокоуровневое понимание сцены.

Как работают нейросети

- Автоизвлечение признаков
- Иерархия: Края $\rightarrow$ Текстуры $\rightarrow$ Объекты
- Обучение на размеченных данных

Почему эффективны нейросети

- Устойчивость к вариациям
- Обобщающая способность
- Масштабируемость

Типы задач

- Classification (Классификация)
- Detection (Детекция)
- Segmentation (Сегментация)

Основные задачи Computer Vision

1. Классификация

Сеть выдает вероятности для каждого класса через softmax

Пример: «Кошка» = 0.95, «Собака» = 0.03

2. Детекция объектов

Локализация + Классификация

Предсказывает: Bounding box (x, y, w, h) + класс

3. Сегментация

Попиксельная классификация

- **Семантическая:** Все объекты одного класса одного цвета
- **Instance:** Каждый объект уникальный цвет

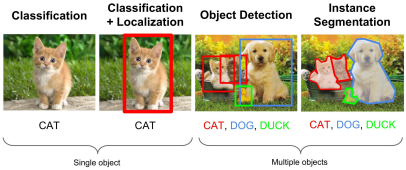

Основные задачи (продолжение)

4. Распознавание лиц

Embeddings → Distance comparison

5. Детекция краев

Gradient filters или CNN

6. Восстановление изображений

Encoder-Decoder архитектура

7. Сопоставление признаков

Keypoint extraction + Matching

8. Реконструкция сцены

Structure from Motion или Depth estimation

9. Анализ движения

Object tracking + Optical flow

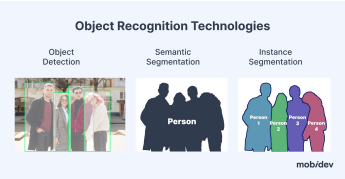

Сверточные нейронные сети (CNN)

Иерархия признаков

- Layer 1: Края, углы, цвета
- Layer 2-3: Текстуры, формы
- Layer 4-5: Части объектов
- FC: Целые объекты

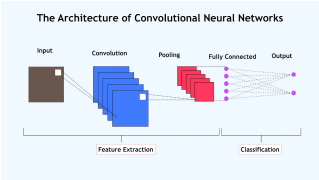

Компоненты CNN

1. **Сверточный слой:** Фильтры $\rightarrow$ Feature maps
2. **ReLU:** $f(x) = \max(0, x)$
3. **Pooling:** Уменьшение размерности
4. **FC слои:** Классификация

Ключевые архитектуры

- **ResNet:** Skip connections
- **Inception:** Параллельные свертки
- **EfficientNet:** Композитное масштабирование

Transfer Learning

Идея

Предобученная сеть уже умеет видеть края, текстуры, формы. Нужно адаптировать под задачу.

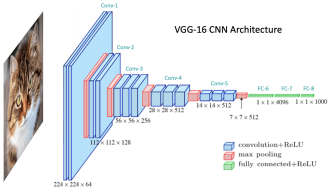

1. Backbone

Предобученная CNN: ResNet, VGG на ImageNet

2. Стратегии обучения

- **Freeze:** Фиксируем ранние слои
- **Fine-tune:** Обучаем поздние слои

3. Замена головы

- Classification: Новые FC слои
- Detection: RPN + classifier
- Segmentation: Decoder

Архитектуры для детекции объектов

Двухстадийные

Faster R-CNN:

- RPN генерирует anchor boxes
- ROI Pooling извлекает признаки
- Классификатор: класс + координаты

Процесс: RPN $\rightarrow$ Regions $\rightarrow$ ROI $\rightarrow$ Output

Одностадийные

YOLO:

- Grid делит изображение
- Предсказывает boxes + confidence
- 45+ FPS

SSD:

- Multi-scale detection
- Лучше на разных размерах

Сравнение: Двухстадийные точнее, одностадийные быстрее

YOLO: You Only Look Once

Grid-based подход

S×S grid (напр. 13×13)

Каждая ячейка предсказывает B bounding boxes

Выход: (x, y, w, h) + confidence + классы

Скорость

YOLOv3: 45+ FPS

YOLOv5: 150+ FPS

Один forward pass

End-to-end обработка без region proposals

NMS убирает дубликаты

Плюсы

- Очень быстрая
- End-to-end
- Глобальный контекст

Минусы

- Хуже на мелких объектах
- Меньше точность на плотных сценах

Эволюция YOLO

Тренды

- Anchor-based → Anchor-free
- CSP, RepVGG backbone
- Neural Architecture Search

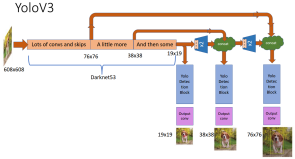

YOLOv1 (2016)
Первая одностадийная, 7×7 grid

YOLOv2 (2017)
Anchor boxes, Darknet-19, 80 классов

YOLO9000 (2017)
WordTree → 9000 классов

YOLOv3 (2018)
Darknet-53, 3 масштаба

YOLOv4 (2020)
CSPDarknet53

YOLOv5 (2020)
PyTorch, 5 размеров

YOLOv8 (2023)
Anchor-free, Mosaic v3

YOLO-NAS (2023)
Neural Architecture Search

SSD: Single Shot MultiBox Detector

Multi-scale Detection

Несколько feature maps разного разрешения

- Низкое разрешение $\rightarrow$ крупные объекты
- Высокое разрешение $\rightarrow$ мелкие объекты

SSD vs YOLO

SSD: лучше на разных масштабах

YOLO: быстрее

Default Boxes (Anchors)

Разные aspect ratios [1, 2, 3, 1/2, 1/3]

Предсказания: Offsets + Confidence

Архитектура

- Backbone: VGG16
- Extra layers для разных масштабов
- Prediction: классификация + локализация

Loss: Confidence + Localization

FPN: Feature Pyramid Network

Идея

Объединение высокого разрешения с высокоуровневой семантикой

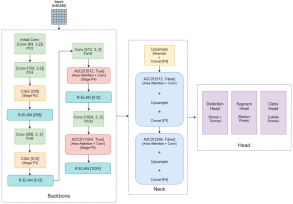

Проблема

Ранние слои: высокое разрешение, низкоуровневые признаки

Поздние слои: низкое разрешение, семантика

Решение

- Bottom-up: Forward pass $\rightarrow$ C2, C3, C4, C5
- Top-down: Upsample + lateral $\rightarrow$ P2, P3, P4, P5

Преимущества

Детекция объектов разных размеров

Используется в: Faster R-CNN + FPN, Mask R-CNN

Архитектуры для сегментации

U-Net

- **Encoder:** сжимает изображение
- **Bottleneck:** сжатая семантика
- **Decoder:** восстанавливает

Skip connections: encoder → decoder

Почему работает?

Encoder: изучает «что»

Decoder: изучает «где»

Mask R-CNN

Faster R-CNN + ветка для масок

- ROI Align: точное выравнивание
- Три выхода: класс + bbox + маска

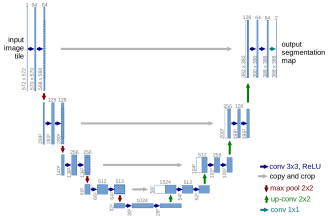

DeepLab: семантическая сегментация

Atrous Convolution

Увеличивает receptive field без роста параметров

rate=2: каждый 2й пиксель

rate=4: каждый 4й пиксель

ASPP

Параллельные свертки с rates 1, 6, 12, 18

Захват объектов разных масштабов

Encoder-Decoder

- Encoder: Backbone + ASPP
- Decoder: Upsample + признаки
- Bilinear upsample 4x

Deep Supervision

Auxiliary loss на промежуточных слоях

Применение

Медицина, спутники, автономное вождение

Генеративные модели

GAN

Generator создает, Discriminator оценивает

Адверсарное обучение

Diffusion Models

Forward: добавляет шум

Reverse: удаляет шум пошагово

U-Net предсказывает шум

VAE

Encoder $\rightarrow$ Latent Space $\rightarrow$ Decoder

Применение

- GAN: StyleGAN, pix2pix
- Diffusion: DALL-E, Stable Diffusion
- Text-to-image генерация
- Inpainting, Super-resolution

Отличия

GAN: адверсарная игра

Diffusion: пошаговое удаление шума

VAE: сжатие в latent space

Применение Computer Vision

Медицина

Сегментация опухолей, классификация рентгена

Автономное вождение

Детекция объектов, сегментация дороги

Промышленность

Контроль качества, сортировка продукции

Сельское хозяйство

Мониторинг посевов, детекция болезней

Безопасность

Face recognition, детекция аномалий

Медицинская визуализация

Сегментация органов, анализ КТ/МРТ

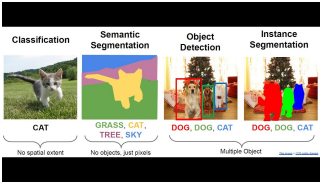

Перспективы развития

Выводы

- Нейросети — стандарт в CV
- Выбор архитектуры под задачу
- Понимать принципы работы

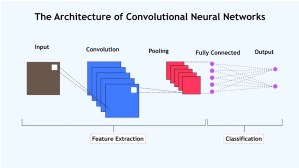

Современные тренды

- Transfer Learning: предобученные модели
- Vision Transformers: patches + attention
- Мультимодальность: CLIP, DALL-E
- Self-supervised: обучение без разметки
- Explainable AI: Grad-CAM
- Генеративные модели: GAN, Diffusion

Главное: Понимать принципы работы архитектур, а не просто применять готовые модели