Языковые модели

BERT, GPT, от RLHF до DeepSeek: как работают современные LLM

Курс «Deep Learning»

2026

Содержание

1. Языковое моделирование: постановка задачи
2. Encoder vs Decoder: два подхода
3. Encoder-only: BERT
4. Decoder-only: GPT
5. Масштабирование: Scaling Laws
6. Instruction Tuning и RLHF
7. DeepSeek и Mixture of Experts

Языковое моделирование

Задача

Предсказать вероятность последовательности токенов:

$$P(w_1, w_2, \ldots, w_n) = \prod_{t=1}^{n} P(w_t \mid w_{1:t-1})$$

Цепное правило: совместная вероятность = произведение условных. **Авторегрессия:** каждый следующий токен зависит от предыдущих.

Пример

$P(\text{«языковая»} \mid \text{«GPT — это»}) = 0.6$
$P(\text{«модель»} \mid \text{«GPT — это»}) = 0.3$
$P(\text{«очень»} \mid \text{«GPT — это»}) = 0.02$

Схема

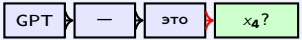

Ключевые понятия

Словарь V**:** 32K–128K токенов (BPE/WordPiece)
Perplexity: $2^{-\frac{1}{n}\sum \log_2 P(x_t)}$

Encoder vs Decoder: три парадигмы

Encoder-only (BERT)

Маскированное языковое моделирование. Бидирекциональный контекст. **Понимание:** классификация, NER, QA.

Decoder-only (GPT)

Авторегрессия (causal mask). **Генерация:** диалог, код, stories.

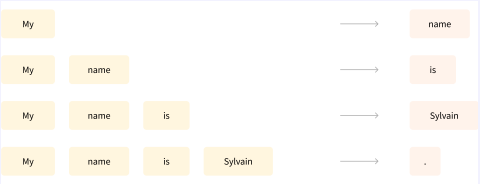

Encoder-Decoder (T5, BART)

Encoder читает вход (бидир.), Decoder генерирует (авторегр.). **Seq2Seq:** перевод, суммаризация.

BERT: Encoder-only

BERT = Bidirectional Encoder Representations from Transformers

- Google, 2018 (Devlin et al.)
- Encoder-only, bi-directional контекст

Размеры: Base: 110M (12 слоёв), Large: 340M (24 слоя)

Masked LM (MLM)

`The [MASK] sat on the mat` → `cat`
15% токенов маскируются: 80% → [MASK], 10% → random, 10% → original

Архитектура

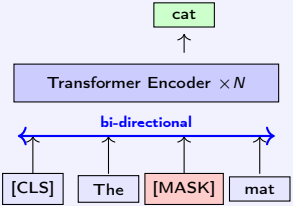

Next Sentence Prediction (NSP)

`[CLS] The cat sat [SEP] It was cute` → `IsNext`

BERT: Fine-tuning

После предобучения BERT донастраивается под конкретную задачу.

Классификация

[CLS]-токен → FC-слой → softmax.
Тональность, спам, тематика.

Token-level

Каждый выходной токен → FC-слой.
NER, POS-теггинг, SQuAD (QA).

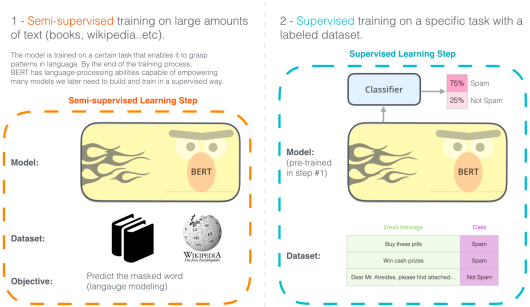

Иллюстрация: Jay Alammar

GPT: Decoder-only

GPT = Generative Pre-trained Transformer

- OpenAI, 2018 (Radford et al.)
- Decoder-only, causal mask
- Токен видит только предыдущие
- Предобучение: next token prediction

Эволюция:

Модель	Параметры	Слои
GPT-1 (2018)	117M	12
GPT-2 (2019)	1.5B	48
GPT-3 (2020)	175B	96
GPT-4 (2023)	≈1.7T	? (MoE)

Ключевое отличие

BERT — bi-directional. GPT — uni-directional (causal).

Архитектура GPT (decoder-only)

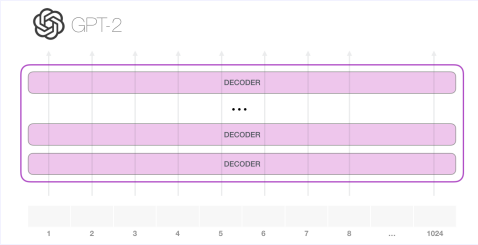

Иллюстрация: Jay Alammar, The Illustrated GPT-2

Функция потерь:

$$\mathcal{L} = -\frac{1}{T}\sum_{t=1}^{T} \log P(x_t \mid x_{<t}; \theta)$$

Обучение GPT: данные и оптимизация

Подготовка данных

- Common Crawl, WebText, Wikipedia, книги
- Токенизация BPE (Byte Pair Encoding)
- Конкатенация с [EOS]-токенами
- Варианты: Pile, C4, RefinedWeb

Один шаг

`GPT is a ??? → target: transformer`

Параметры обучения

Параметр	**Значение**
Оптимизатор	AdamW ($\beta_1 = 0.9$, $\beta_2 = 0.95$)
LR schedule	Cosine decay + warmup
Max LR	3×10^{-4} (GPT-3 175B)
Batch size	3.2M токенов
Weight decay	0.1
Gradient clipping	1.0
Precision	FP16 / BF16 / FP8

Chinchilla

GPT-3 (175B) обучался на 300B токенов. Нужно $\approx 20\times$ больше токенов, чем параметров.

Инференс GPT

Авторегрессия

Prompt $\to$ GPT $\to$ [logits] $\to$ [sampling] $\to$ next token. Добавить, повторить.

KV Cache

- Сохраняем K и V на каждом слое
- На новом шаге: только новый токен
- $O(n^2) \to O(n)$ на токен

Стратегии декодирования

Метод	**Описание**	**Хар-ка**
Greedy	$\arg\max P$	просто, циклы
Top-k	ресемплинг из k	$k = 40$–100
Top-p	nucleus: кум. p	$p = 0.9$–0.95
Temperature	$P \propto e^{l/T}$	$T = 0.7$–1.0
Beam search	k гипотез	перевод

От GPT-1 к GPT-4: масштабирование

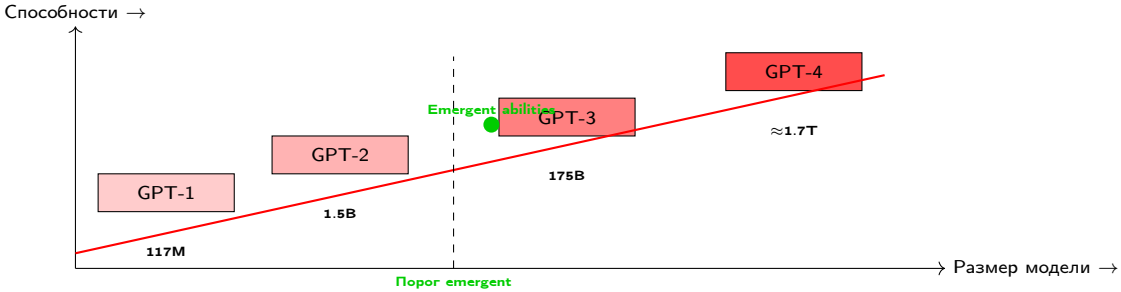

In-Context Learning

Few-shot примеры в промпте. GPT-2 не мог, GPT-3 — да.

Chain-of-Thought

«Давайте подумаем шаг за шагом» → рассуждения.

Few-shot

Zero / one / few-shot. Точность растёт с числом примеров.

Scaling Laws

Kaplan et al., 2020

Loss $\propto N^{-0.076} \cdot D^{-0.103}$

- Степенной закон от N и D
- N важнее D (при фикс. бюджете)

Chinchilla (Hoffmann et al., 2022)

- Для 175B нужно $\approx$ 3.7T токенов
- Chinchilla 70B / 1.4T $>$ GPT-3 175B

Параметры : Токены

Модель	**Параметры**	**Токены**
GPT-3	175B	300B (1.7×)
Chinchilla	70B	1.4T (20×)
LLaMA 65B	65B	1.4T (21.5×)
DeepSeek-V3	671B	14.8T (22×)

Вывод

Большинство моделей недообучены. Стандарт: $\approx$ 20× больше токенов, чем параметров.

Instruction Tuning

Проблема

Raw GPT-3 продолжает текст, а не следует инструкциям.
`Переведи: Hello` → `«Hello» может быть...`
А нужно: `Здравствуйте`

Решение: SFT на парах (инструкция, ответ).

SFT workflow

↑

Instruction-tuned

Датасеты

- **FLAN:** 60+ NLP-задач → инструкции
- **Alpaca:** 52K инструкций от GPT-3.5
- **OpenAssistant:** краудсорсинг

Формат диалога

```
<|system|> Ты полезный ассистент
<|user|> Переведи: Hello
<|assistant|> Здравствуйте
```

Ограничение: SFT решает follow instructions, но не alignment.

RLHF: трёхшаговый pipeline

1. SFT

- Пара (промпт, ответ)
- Next-token loss
- 10K–100K примеров

2. Reward Model

- Несколько ответов
  → Человек: A>B>C
- $P(A > B) = \sigma(r_A - r_B)$

3. PPO

- RL с наградой от RM
- KL penalty к SFT
- $\mathcal{L} = \mathbb{E}[-r] + \beta D_{KL}$

Пример обучения RM:

`Prompt → [Ответ A] [Ответ B] [Ответ C]`
`Человек: B > A > C → RM учится`

От InstructGPT к ChatGPT

InstructGPT (Ouyang et al., 2022)

- GPT-3 $\rightarrow$ SFT на 13K инструкций
- RM на 33K сравнений
- PPO fine-tuning
- **Результат:** 1.3B $>$ 175B GPT-3

Ключевой инсайт: alignment $>$ размер модели.

ChatGPT (Nov 2022)

- SFT + RM + PPO на диалогах
- Multi-turn, safety
- Роли: system/user/assistant

Альтернативы RLHF

DPO (2023)	Прямая оптимизация без RM и RL
GRPO	Без Critic-сети (DeepSeek)
Constitutional AI	Самооценка по правилам
RLAIF	RM $\rightarrow$ LLM-фидбек

DeepSeek: Reasoning через RL

DeepSeek-R1 (январь 2025)

Идея: обучение рассуждению через RL, без SFT.

1. Cold-start: небольшой SFT
2. GRPO: награда за ответ + формат
3. Self-evolution: CoT emerges

GRPO: без Critic-сети. Оценка по группе ответов.

DeepSeek-V3 (декабрь 2024)

- 671B пар., 37B активных (MoE, 256 экспертов)
- 14.8T токенов, FP8
- Multi-Token Prediction
- **Стоимость:** $5.5M (10× дешевле)

Архитектурные решения

- MLA: сжатие KV кеша в 4×
- Мелкозернистые эксперты
- Shared expert + loss-free balancing

Mixture of Experts (MoE)

Dense vs MoE

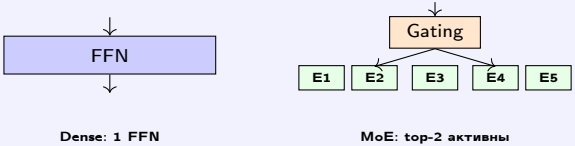

Формула: $\mathrm{MoE}(x) = \sum_i G(x)_i \cdot E_i(x)$,
$G(x) = \mathrm{softmax}(W_g x)$

Плюсы / Минусы

+ Больше параметров, те же FLOPs
+ Качество ≈ dense полного размера
– Все эксперты в VRAM
– Load balancing, сложный fine-tuning

Примеры

Модель	Всего	Активно
Mixtral 8x7B	47B	12.9B
DeepSeek-V2	236B	21B
DeepSeek-V3	671B	37B
GPT-4 (rum.)	≈1.7T	≈200B

Современные тренды LLM

Architecture
- MoE — новый стандарт
- MQA / GQA attention
- RoPE, ALiBi embeddings
- Mamba / SSM

Training
- FP8 / mixed precision
- Multi-Token Prediction
- Curriculum learning
- Data quality > quantity

Alignment
- DPO, GRPO
- Constitutional AI
- RLAIF
- Safety at scale

Inference
- KV cache quantization
- Speculative decoding
- Continuous batching

Reasoning
- Chain-of-Thought
- Test-time compute scaling
- Agentic AI / tool use

Open Source
- LLaMA, Qwen, DeepSeek
- Mixtral, Command R+

Заключение

Что мы узнали:

- LM: $P(\text{next} \mid \text{context})$
- BERT: encoder, bi-directional, MLM
- GPT: decoder, авторегрессия, KV cache
- Scaling Laws: $N + D =$ качество
- RLHF: SFT $\rightarrow$ RM $\rightarrow$ PPO
- DeepSeek: reasoning + MoE

Ключевые идеи

- **Emergent:** способности при масштабировании
- **Alignment:** маленькая aligned $>$ большая
- **Sparsity:** MoE — больше за те же FLOPs

Дальше: мультимодальные модели, агенты, video gen.